

Sistema inteligente de apoyo a la decisión para la gestión hídrica agrícola

Definición del caso de uso de ciencia de datos

Práctica final. Módulo 2. La ciencia de datos: técnicas de análisis, minería y visualización

Máster en Data Science, curso 2025/2026

Luis Moreno Díaz, Adrián Pérez Lombal, Manuel Ramos Alascio y Alicia Santamaría
Román

1. Descripción del problema

El regadío concentra alrededor del 70 % de las extracciones mundiales de agua dulce y permite obtener cerca del 40 % de la producción agrícola en aproximadamente el 20 % de la superficie cultivada, lo que muestra tanto su capacidad para sostener la producción como la necesidad de mejorar la productividad del agua y evitar aplicaciones superiores a las necesidades reales de los cultivos (FAO, 2021).

Este reto es especialmente relevante en el sur de Europa. El estrés hídrico afecta cada año a cerca del 20 % del territorio europeo y al 30 % de su población, con una incidencia más intensa en la región mediterránea (European Environment Agency [EEA], 2021), y las proyecciones climáticas anticipan un aumento de los riesgos de calor, sequía y menor disponibilidad hídrica en los próximos años (Intergovernmental Panel on Climate Change [IPCC], 2022).

En España, el regadío ocupa alrededor del 22 % de la superficie cultivada y genera aproximadamente el 65 % de la Producción Final Vegetal, una importancia productiva que ha llevado a la administración a situar la digitalización, la tecnificación y la adaptación a escenarios de menor disponibilidad hídrica entre las prioridades del sector (Real Decreto 854/2022, 2022). La programación del riego depende, sin embargo, de numerosos factores (el tipo de cultivo y su fase fenológica, el suelo, la meteorología, la precipitación efectiva y la eficiencia del sistema de riego), lo que convierte la decisión de cuándo y cuánto regar en un problema complejo que los calendarios fijos o los valores medios resuelven de forma limitada.

El problema que aborda este proyecto es, por tanto, doble. Por un lado, la dispersión de la información meteorológica, agrometeorológica e hidrológica entre distintas fuentes públicas dificulta su uso conjunto para tomar una decisión operativa. Por otro, la ausencia de una herramienta que traduzca esos datos en una recomendación de riego concreta y comprensible deja la decisión final apoyada casi en exclusiva en la experiencia del agricultor, sin una referencia adicional que la contraste.

2. Definición del caso de uso

Se plantea el desarrollo de un sistema inteligente de apoyo a la decisión (DSS) que integre variables meteorológicas, agrometeorológicas e hidrológicas junto con información del tipo de cultivo y su localización, y que transforme esa información en una recomendación de riego trazable y comprensible. El sistema está destinado a agricultores particulares, cooperativas y gestores de explotaciones agrícolas, y busca mejorar la decisión sobre el momento y la cantidad de agua a aplicar en cada parcela.

El proyecto se concibe como una herramienta de apoyo y no como un mecanismo autónomo que sustituya el criterio agronómico del usuario. Un sistema de apoyo a la decisión organiza información y aplica modelos para ayudar a resolver decisiones semiestructuradas, es decir, problemas en los que una parte puede formalizarse mediante datos y modelos, pero otra depende del contexto y de la experiencia del agricultor (Shim et al., 2002). En un estudio sobre plantaciones comerciales de cítricos en el sureste de España, Navarro-Hellín et al. (2016) integraron variables climáticas y de suelo con modelos de aprendizaje automático para estimar necesidades semanales de riego, contrastando los resultados con las decisiones de un experto, lo que respalda la viabilidad de este enfoque siempre que exista una calibración local y una

validación adecuada.

La solución de ciencia de datos prevista combina, por tanto, una referencia agronómica basada en la evapotranspiración de referencia y en los coeficientes de cultivo (Allen et al., 1998), con modelos de aprendizaje supervisado capaces de mejorar esa estimación a partir de los datos históricos y actuales disponibles para la zona de estudio.

3. Datos necesarios

El proyecto sigue un enfoque multifuente para cubrir las distintas dimensiones del problema, combinando fuentes oficiales de acceso público con las que ya se cuenta experiencia previa dentro del equipo.

- Datos meteorológicos, procedentes de AEMET OpenData: históricos y previsiones de precipitación, temperatura, humedad relativa y presión atmosférica (Agencia Estatal de Meteorología [AEMET], s. f.).
- Datos agrometeorológicos, procedentes del Sistema de Información Agroclimática para el Regadío (SiAR): información de una red de estaciones orientada específicamente a la planificación y gestión eficiente del riego (Ministerio de Agricultura, Pesca y Alimentación [MAPA], s. f.).
- Datos hidrológicos, procedentes del Boletín Hidrológico semanal del MITECO, con información agregada sobre el estado de embalses y cuencas, cuyo carácter provisional exige un proceso de validación antes de incorporarlos al sistema (Ministerio para la Transición Ecológica y el Reto Demográfico [MITECO], s. f.).
- Datos de cultivo, con los requerimientos específicos de evapotranspiración (ETc) para frutas, verduras y hortalizas, tomados como referencia agronómica de partida (Allen et al., 1998), y complementados de forma opcional con información del sector agropecuario de CREA.

La variable objetivo prevista es la necesidad o dosis de riego, expresada en un horizonte diario o semanal según cultivo y localización. Cada fuente conservará su marca temporal, su localización y su procedencia, de forma que los datos puedan integrarse de manera consistente y quede trazado el origen de cada valor utilizado en el modelo.

4. Técnicas propuestas

La estimación de la demanda de riego se plantea como un problema de regresión, ya que la variable objetivo es continua. La literatura sitúa la gestión del agua y del suelo entre las principales áreas de aplicación del aprendizaje automático en agricultura (Liakos et al., 2018), con algoritmos que van desde modelos lineales, que sirven como referencia interpretable, hasta bosques aleatorios y métodos de potenciación como XGBoost, cuyo rendimiento depende en gran medida de la calidad y representatividad de los datos disponibles (Benos et al., 2021).

Se comparará cada modelo candidato con una línea base agronómica calculada mediante la metodología FAO-56 (Allen et al., 1998), de forma que la complejidad adicional de un modelo de aprendizaje automático solo se justifique si aporta una mejora reproducible frente a esa referencia. La validación de los modelos respetará la estructura temporal de los datos,

entrenando con información pasada y evaluando sobre periodos posteriores, ya que una partición aleatoria podría subestimar el error esperado ante condiciones no observadas durante el entrenamiento (Roberts et al., 2017). Para mejorar la trazabilidad de las recomendaciones se prevé además incorporar técnicas de interpretabilidad como SHAP, que permiten conocer qué variables influyen en cada predicción concreta (Lundberg y Lee, 2017).

5. Resultados esperados

El resultado principal es una estimación de la necesidad de riego por cultivo y localización, ajustada mediante el entrenamiento del modelo con datos históricos y contrastada frente a la referencia agronómica FAO-56. Este resultado se presentará a través de un cuadro de mando interactivo que permita seleccionar cultivo y localización, y consultar tanto la recomendación como las variables que más han influido en ella y la vigencia de los datos utilizados.

Se espera igualmente disponer de un flujo de datos reproducible, documentado y con controles de calidad, que permita repetir el proceso de extracción, integración y modelado con datos actualizados una vez finalizado el proyecto, y de una comparación objetiva entre los distintos algoritmos evaluados que justifique la elección final del modelo.

6. Métricas de evaluación

La evaluación del sistema se plantea en varios planos, ya que la calidad de un sistema de apoyo a la decisión no depende solo de la precisión del modelo (McCown, 2002; Rose et al., 2016).

- Plano predictivo. Error absoluto medio (MAE), raíz del error cuadrático medio (RMSE) y coeficiente de determinación (R^2) del modelo frente a la referencia agronómica FAO-56, calculados sobre una partición de validación que respete la estructura temporal de los datos.
- Plano agronómico. Coherencia de las recomendaciones generadas con el balance hídrico del cultivo y con los límites operativos del sistema de riego, comprobando que ninguna recomendación se aleje de forma injustificada de la estimación de referencia.
- Plano de trazabilidad. Cobertura y vigencia de los datos utilizados en cada predicción, y capacidad del sistema para señalar cuándo una variable de entrada se sitúa fuera del rango observado durante el entrenamiento.
- Plano de uso. Comprensión y utilidad percibida de las recomendaciones por parte de un usuario no especializado en ciencia de datos, un factor que la literatura identifica como determinante para la adopción real de este tipo de herramientas (Rose et al., 2016).

7. Riesgos, limitaciones y próximos pasos

El proyecto presenta varios riesgos que conviene anticipar. La disponibilidad y la calidad de los datos de las APIs públicas no está garantizada de forma continua, y pueden producirse fallos de servicio, retrasos de actualización o cambios en el formato de la información. El carácter provisional de algunos datos, como los del Boletín Hidrológico, exige además un proceso de

validación antes de su uso (Ministerio para la Transición Ecológica y el Reto Demográfico [MITECO], s. f.). A esto se suma el riesgo de que el modelo pierda precisión con el tiempo si cambian las condiciones climáticas, el manejo del cultivo o la instrumentación empleada, un fenómeno habitual en aplicaciones de aprendizaje automático sobre datos agrícolas (Benos et al., 2021; Wolfert et al., 2017).

Como limitación, el alcance del proyecto se acota a una zona geográfica concreta de alta demanda hídrica y a un conjunto delimitado de cultivos, por lo que los resultados no podrán generalizarse de forma automática a otras regiones o especies sin una recalibración previa. El sistema tampoco sustituye el criterio agronómico del usuario final, sino que se plantea como una herramienta de apoyo cuya recomendación puede y debe ser contrastada por la persona responsable de la explotación.

Los próximos pasos del proyecto incluyen completar el apartado de metodología y arquitectura del sistema, definir de forma más precisa la zona de estudio y el periodo histórico de entrenamiento, construir el pipeline de extracción y carga de datos mediante Apache Hop y MySQL, y comenzar el análisis exploratorio que permita validar las hipótesis de partida sobre la relación entre las variables meteorológicas y la demanda de riego.

Anexo. Estructura del repositorio en GitHub

Como parte de la organización del proyecto en GitHub, prevista en la primera parte de esta práctica, se ha definido la siguiente estructura de carpetas para separar los datos, el código, la documentación, los modelos y los resultados del proyecto.

```
tfm-regadio-dss/
|
|-- data/                                Datos del proyecto (no se suben datos reales, ver .gitignore)
|   |-- raw/                             Datos descargados tal cual llegan de AEMET, SiAR y MITECO
|   |-- interim/                         Datos intermedios, todavía en proceso de limpieza
|   |-- processed/                       Datos ya depurados y listos para el análisis o el modelado
|   |-- external/                       Datos auxiliares de terceros
|
|-- database/                            Todo lo relativo al almacenamiento en MySQL
|   |-- schema/                          Scripts de creación de tablas y relaciones
|   |-- etl_apache_hop/                 Transformaciones y jobs de Apache Hop
|
|-- notebooks/                           Cuadernos Jupyter de exploración
|
|-- src/                                 Código Python reutilizable del proyecto
|   |-- data/                             Extracción y carga de datos desde las APIs
|   |-- features/                         Construcción de variables
|   |-- models/                          Entrenamiento y evaluación de modelos predictivos
|   |-- dss/                             Lógica de recomendación del sistema de apoyo a la decisión
|   |-- visualization/                   Funciones de apoyo para gráficos y figuras
|
|-- models/                              Modelos entrenados y serializados
|
|-- results/                             Resultados generados por el proyecto
|   |-- figures/                          Gráficos y figuras finales
|   |-- reports/                         Informes de evaluación, métricas y análisis
|
|-- dashboards/                          Cuadros de mando (Power BI o Tableau)
|
|-- docs/                                Documentación del TFM
|   |-- anteproyecto/                    Anteproyecto y propuesta inicial del proyecto
|   |-- memoria/                         Memoria del TFM en curso
|   |-- entregables_modulos/             Entregas de las distintas prácticas del máster
|   |-- figuras/                         Imágenes utilizadas en la documentación
|
|-- references/                          Material de apoyo bibliográfico
|   |-- bibliografia/                   Registro de citas y referencias en formato APA
|
|-- tests/                               Comprobaciones automáticas del código
|-- docker/                             Ficheros de contenedor para el entorno reproducible
|-- config/                             Plantilla de variables de entorno (.env.example)
|-- .github/workflows/                  Automatizaciones (integración continua)
|
|-- .gitignore
|-- environment.yml
|-- requirements.txt
|-- ORGANIZACION_Y_VERSIONADO.md
|-- README.md
```

El repositorio incluye además un fichero README.md con esta misma estructura documentada, un .gitignore que excluye los datos reales y las credenciales de acceso a las APIs, un fichero de dependencias del entorno de Python, y un documento aparte que explica la organización del trabajo en equipo y el control de versiones mediante ramas, commits e issues.

Referencias bibliográficas

- Agencia Estatal de Meteorología. (s. f.). *AEMET OpenData*. Recuperado el 16 de septiembre de 2026, de <https://opendata.aemet.es/centrodedescargas/inicio>
- Allen, R. G., Pereira, L. S., Raes, D., y Smith, M. (1998). *Crop evapotranspiration: Guidelines for computing crop water requirements* (FAO Irrigation and Drainage Paper No. 56). Food and Agriculture Organization of the United Nations. <https://www.fao.org/4/x0490e/x0490e00.htm>
- Benos, L., Tagarakis, A. C., Dolias, G., Berruto, R., Kateris, D., y Bochtis, D. (2021). Machine learning in agriculture: A comprehensive updated review. *Sensors*, 21(11), 3758. <https://doi.org/10.3390/s21113758>
- European Environment Agency. (2021). *Water resources across Europe, confronting water stress: An updated assessment* (EEA Report No. 12/2021). <https://www.eea.europa.eu/publications/water-resources-across-europe-confronting-water-stress>
- Food and Agriculture Organization of the United Nations. (2021). *The state of the world's land and water resources for food and agriculture, systems at breaking point*. <https://doi.org/10.4060/cb7654en>
- Intergovernmental Panel on Climate Change. (2022). *Climate change 2022: Impacts, adaptation and vulnerability* (H. O. Pörtner et al., Eds.). Cambridge University Press. <https://doi.org/10.1017/9781009325844>
- Liakos, K. G., Busato, P., Moshou, D., Pearson, S., y Bochtis, D. (2018). Machine learning in agriculture: A review. *Sensors*, 18(8), 2674. <https://doi.org/10.3390/s18082674>
- Lundberg, S. M., y Lee, S. I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30, 4765–4774. https://proceedings.neurips.cc/paper_files/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html
- McCown, R. L. (2002). Locating agricultural decision support systems in the troubled past and socio-technical complexity of models for management. *Agricultural Systems*, 74(1), 11–25. [https://doi.org/10.1016/S0308-521X\(02\)00020-3](https://doi.org/10.1016/S0308-521X(02)00020-3)
- Ministerio de Agricultura, Pesca y Alimentación. (s. f.). *Sistema de Información Agroclimática para el Regadío (SiAR)*. Recuperado el 16 de septiembre de 2026, de <https://servicio.mapa.gob.es/siarweb/>
- Ministerio para la Transición Ecológica y el Reto Demográfico. (s. f.). *El Boletín Hidrológico semanal*. Recuperado el 16 de septiembre de 2026, de <https://www.miteco.gob.es/es/agua/temas/evaluacion-de-los-recursos-hidricos/boletin-hidrologico.html>
- Navarro-Hellín, H., Martínez-del-Rincón, J., Domingo-Miguel, R., Soto-Valles, F., y Torres-Sánchez, R. (2016). A decision support system for managing irrigation in agriculture. *Computers and Electronics in Agriculture*, 124, 121–131. <https://doi.org/10.1016/j.compag.2016.04.003>
- Real Decreto 854/2022, de 11 de octubre, por el que se crean la Mesa Nacional del Regadío y el Observatorio de la Sostenibilidad del Regadío. *Boletín Oficial del Estado*, 245, de 12 de octubre de 2022, 139046–139055. <https://www.boe.es/eli/es/rd/2022/10/11/854>
- Roberts, D. R., Bahn, V., Ciuti, S., Boyce, M. S., Elith, J., Guillera-Aroita, G., Hauenstein, S., Lahoz-Monfort, J. J., Schröder, B., Thuiller, W., Warton, D. I., Wintle, B. A., Hartig, F., y Dormann, C. F. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, 40(8), 913–929. <https://doi.org/10.1111/ecog.02881>
- Rose, D. C., Sutherland, W. J., Parker, C., Lobley, M., Winter, M., Morris, C., Twining, S., Ffoulkes, C., Amano, T., y Dicks, L. V. (2016). Decision support tools for agriculture: Towards effective design and delivery. *Agricultural Systems*, 149, 165–174. <https://doi.org/10.1016/j.agsy.2016.09.009>

- Shim, J. P., Warkentin, M., Courtney, J. F., Power, D. J., Sharda, R., y Carlsson, C. (2002). Past, present, and future of decision support technology. *Decision Support Systems*, 33(2), 111–126. [https://doi.org/10.1016/S0167-9236\(01\)00139-7](https://doi.org/10.1016/S0167-9236(01)00139-7)
- Wolfert, S., Ge, L., Verdouw, C., y Bogaardt, M. J. (2017). Big data in smart farming, a review. *Agricultural Systems*, 153, 69–80. <https://doi.org/10.1016/j.agsy.2017.01.023>