

Sistema inteligente de apoyo a la decisión para la gestión hídrica agrícola

Process Mining, estimación cloud y gestión del ciclo de vida con MLflow

Práctica final. Módulo 9

Máster en Data Science, curso 2025/2026

Luis Moreno Díaz, Adrián Pérez Lombal, Manuel Ramos Alascio y Alicia Santamaría Román

Índice

1. Descripción del problema desde una perspectiva de procesos
 2. Definición del caso de uso de Process Mining
 3. Procesos objeto de análisis
 4. Datos necesarios y registros de eventos
 5. Técnicas propuestas
 6. Resultados esperados
 7. Métricas de evaluación
 8. Estimación de recursos cloud
 9. Gestión del ciclo de vida con MLflow
 10. Caso práctico aplicado
 11. Riesgos, limitaciones y próximos pasos
 12. Enlace Github Proyecto.
- Referencias bibliográficas
- Anexo. Red de Petri conceptual

1. Descripción del problema desde una perspectiva de procesos

El Trabajo Fin de Máster plantea un sistema inteligente de apoyo a la decisión, o DSS, capaz de estimar la necesidad de riego diaria y semanal para distintos cultivos y localizaciones de España. La recomendación combina información meteorológica, agrometeorológica, hidrológica y agronómica. El usuario mantiene la decisión final, porque una herramienta de este tipo debe apoyar y documentar el criterio profesional, no sustituirlo (Rose et al., 2016).

El piloto de esta práctica se acota al pimiento cultivado bajo invernadero en la provincia de Almería. Esta elección permite concretar el flujo de trabajo, los eventos y los recursos necesarios sin reducir el alcance general del TFM. El cultivo y la zona funcionan como un caso verificable sobre el que diseñar el proceso; una ampliación posterior a otras combinaciones exigirá recalibrar coeficientes, fuentes y modelos.

Desde una perspectiva de procesos, el problema no termina cuando el modelo calcula una dosis. La recomendación solo genera valor si los datos llegan a tiempo, superan controles de calidad, se utiliza una versión identificable del modelo, el usuario comprende la salida y queda registrado qué decisión tomó. Un error de API, una lectura caducada o una validación omitida pueden producir una recomendación tardía o poco fiable aunque el algoritmo predictivo tenga buenas métricas.

La necesidad de negocio consiste en convertir un conjunto de operaciones dispersas en un proceso observable y mejorable. Process Mining permite reconstruir ese proceso a partir de los rastros que dejan los sistemas de información, comparar la ejecución real con el flujo previsto y localizar demoras, reintentos y actividades omitidas (van der Aalst, 2016).

2. Definición del caso de uso de Process Mining

El caso de uso analiza dos recorridos relacionados pero distintos. El primero es el proceso de negocio que comienza cuando un agricultor o técnico consulta una parcela y termina cuando registra la dosis aplicada o justifica una decisión diferente. El segundo es el proceso técnico que extrae los datos, los valida, construye variables y genera la recomendación. Separarlos evita mezclar la experiencia del usuario con las incidencias internas del pipeline.

Elemento	Definición aplicada al proyecto
Usuarios	Agricultores, técnicos de cooperativas, responsables de riego y equipo de datos del TFM.
Decisión que se mejora	Cuándo regar y qué dosis aplicar, con evidencia sobre la calidad y vigencia de los datos.
Unidad de análisis de negocio	Una consulta de riego para una parcela, un cultivo y una fecha determinadas.
Unidad de análisis técnica	Una ejecución de ingesta, validación, transformación y generación de recomendaciones.
Resultado	Modelo del proceso real, variantes, desviaciones, tiempos de ciclo y acciones de mejora priorizadas.
Alcance del piloto	Pimiento bajo invernadero en Almería; el diseño permanece extensible a otras zonas y cultivos.

3. Procesos objeto de análisis

3.1 Proceso de decisión de riego

El proceso de negocio empieza con la identificación de la parcela, el cultivo y la fecha. El DSS comprueba que las variables críticas estén disponibles y vigentes. Si faltan datos, la consulta no avanza como si fuese completa: se solicita una actualización y se vuelve a validar. Cuando la entrada

es válida, el sistema calcula la dosis, muestra los factores que la explican y presenta su nivel de confianza. El responsable puede aceptar, ajustar o rechazar la propuesta y debe registrar la dosis final y, cuando proceda, el motivo del cambio.

Proceso de decisión de riego

El DSS prepara una recomendación explicable; el responsable conserva la decisión final.




Figura 1. Proceso de negocio para una consulta de riego.

3.2 Proceso técnico de datos y modelado

El proceso técnico integra AEMET, SiAR y el Boletín Hidrológico del MITECO, además de los parámetros agronómicos del cultivo. Los datos se conservan primero en una capa raw, se normalizan las fechas y unidades, se aplican reglas de calidad y se construyen variables como la evapotranspiración del cultivo, la precipitación efectiva, los retardos y las medias móviles. La referencia agronómica parte de FAO-56, donde la evapotranspiración del cultivo se obtiene a partir de la evapotranspiración de referencia y el coeficiente de cultivo (Allen et al., 1998).

Cada ejecución debe quedar asociada a una versión de datos y a una versión del modelo. Si una extracción falla o una regla de calidad no se cumple, el proceso genera una alerta, corrige o reintenta de forma controlada y conserva el motivo. El DSS no debe ocultar que una recomendación procede de datos incompletos o antiguos.

Proceso técnico del DSS

Cada ejecución conserva identificadores de fuente, versión de datos, estado y duración.




Figura 2. Pipeline técnico desde las fuentes hasta la recomendación.

3.3 Mapa de procesos

Tipo	Procesos incluidos
Estratégicos	Gobierno del dato, criterios agronómicos, gestión del riesgo, seguridad y política de actualización de modelos.
Operativos	Consulta y decisión de riego; ingesta, validación, transformación, predicción y publicación de la recomendación.
De apoyo	Mantenimiento de APIs y MySQL, monitorización, soporte al usuario, gestión de credenciales y documentación.

4. Datos necesarios y registros de eventos

La minería de procesos requiere un event log coherente. Como mínimo, cada evento debe contener un identificador de caso, una actividad y una marca temporal; los atributos adicionales permiten explicar las desviaciones y medir su impacto (IEEE, 2016; van der Aalst, 2016). Las parcelas se identificarán mediante claves pseudonimizadas y se evitará almacenar datos personales que no sean necesarios para el análisis.

Campo	Uso en el proceso de negocio	Uso en el proceso técnico
case_id	Consulta de parcela y fecha	Ejecución del pipeline
timestamp	Momento de cada interacción	Inicio y fin de cada tarea
activity	Consultar, recomendar, decidir, registrar	Extraer, validar, transformar, predecir
resource	Aplicación, DSS o responsable	API, Apache Hop, MySQL o modelo
status	Completo, advertencia o cancelado	Correcto, error, reintento o bloqueado
context	Cultivo, fase, dosis propuesta y final	Fuente, filas, versión de datos y modelo

4.1 Ejemplo del registro de decisión

La tabla siguiente es ilustrativa y no representa agricultores ni ejecuciones reales. Su función es mostrar la estructura que deberá generar la aplicación.

Caso	Fecha y hora	Actividad	Recurso	Contexto
R001	06-05 07:10	Consultar parcela	Aplicación	Pimiento; fase vegetativa
R001	06-05 07:11	Validar datos	DSS	Entradas vigentes
R001	06-05 07:12	Mostrar recomendación	Modelo v0.3	4,2 mm/día; confianza media
R001	06-05 07:15	Aceptar recomendación	Responsable	Dosis final 4,2 mm/día
R002	06-05 07:20	Consultar parcela	Aplicación	Lectura de humedad antigua
R002	06-05 08:05	Completar datos	Técnico	Medición actualizada
R002	06-05 08:10	Ajustar recomendación	Responsable	3,6 a 3,2 mm/día; motivo registrado

4.2 Ejemplo del registro del pipeline

Caso	Fecha y hora	Actividad	Estado	Duración
E1001	06-05 03:00:00	Extraer datos meteorológicos	Correcto	18 s
E1001	06-05 03:00:18	Validar y normalizar	Correcto	20 s
E1001	06-05 03:00:38	Cargar data mart	Correcto	9 s
E1001	06-05 03:00:47	Generar recomendación	Correcto	1 s
E1002	07-05 03:00:00	Extraer datos meteorológicos	Timeout	30 s
E1002	07-05 03:00:30	Reintentar extracción	Correcto	16 s
E1002	07-05 03:00:46	Validar y normalizar	Correcto	21 s

R002 permite medir el tiempo que añade un dato caducado y E1002 muestra el efecto de un timeout. Al acumular casos reales será posible comprobar si estas variantes se concentran en una fuente, una franja horaria o un tipo de parcela.

5. Técnicas propuestas

PM4Py encaja con el entorno Python del TFM y permite preparar event logs, descubrir modelos, analizar variantes y comprobar conformidad (Berti et al., 2019). El análisis se desarrollará en tres niveles complementarios.

Técnica	Aplicación	Salida esperada
Descubrimiento	Directly-Follows Graph e Inductive Miner sobre ambos event logs.	Flujo real, variantes, bucles, actividades infrecuentes y red de Petri.
Conformidad	Alineamientos o token replay frente al proceso definido.	Casos que recomiendan sin validar, omiten registros o incumplen el orden.
Mejora y rendimiento	Análisis de tiempos de ciclo, esperas, cuellos de botella y atributos.	Priorización de fuentes inestables, validaciones lentas y puntos de abandono.

El descubrimiento no se utilizará para convertir cualquier variante observada en un comportamiento aceptable. La verificación de conformidad mantendrá reglas no negociables, como validar los datos antes de calcular la dosis y registrar la versión del modelo que produjo la recomendación. El análisis de mejora añadirá información temporal y contextual para decidir qué incidencia conviene corregir primero.

6. Resultados esperados

- Un modelo del proceso real de consulta y decisión, con las variantes de aceptación, ajuste, rechazo y falta de datos.
- Un modelo del pipeline que muestre reintentos, errores de fuente, tareas omitidas y tiempos de espera.
- Un cuadro de indicadores que relacione calidad del dato, tiempo de proceso, versión del modelo y decisión final.
- Una lista priorizada de mejoras, con evidencia sobre su frecuencia y su impacto operativo.
- Trazabilidad entre la recomendación mostrada al usuario y el experimento de MLflow que generó el modelo.

Durante la fase académica estos resultados validan la arquitectura y el método de observación. No se atribuirá un ahorro de agua al sistema sin disponer de registros reales de aplicación, una referencia de comparación y validación agronómica.

7. Métricas de evaluación

Plano	Indicador	Definición o criterio inicial
Proceso técnico	Ejecuciones correctas	Porcentaje de pipelines que terminan sin error. Objetivo inicial igual o superior al 98 %.
Proceso técnico	Tiempo de ciclo	Desde la primera extracción hasta el data mart disponible; debe finalizar antes de la ventana diaria de consulta.
Calidad	Cobertura de variables críticas	Consultas con entradas vigentes y válidas sobre el total. Nunca se completan faltantes sin señalarlos.
Conformidad	Fitness y desviaciones	Grado de reproducción del log por el modelo y número de trazas que omiten una validación obligatoria.
Experiencia	Latencia de consulta	Menos de 3 segundos cuando los datos ya están procesados.
Uso	Aceptación y ajuste	Distribución de decisiones y motivos. Es un indicador descriptivo, no una prueba automática de calidad.
Modelo	MAE, RMSE y R ²	Validación temporal frente a FAO-56 y análisis separado por periodo y condiciones.

8. Estimación de recursos cloud

El dimensionamiento se formula como una estimación reproducible, no como una factura cerrada. Se adopta un escenario piloto de 100 parcelas, tres fuentes públicas, una ejecución diaria del ETL, hasta 1.000 consultas al día, dos años de histórico y un reentrenamiento semanal. El cálculo toma como referencia una región europea y precios de pago por uso. Azure indica que la calculadora sirve para estimar combinaciones de servicios y que el precio final depende de región, modalidad, transferencia y acuerdo comercial (Microsoft, 2026a, 2026b).

Componente	Cantidad de cálculo	Configuración inicial
Almacenamiento	100 GB de datos y 20 GB de artefactos/logs el primer año	Blob Storage LRS; ciclo de vida para mover históricos a una capa fría.
ETL diario	30 ejecuciones de 15 min	7,5 vCPU-h y 15 GB-h al mes en un contenedor de 1 vCPU y 2 GB.
Base de datos	730 h/mes y 32 GB	MySQL Flexible Server B1ms, 1 vCore y 2 GiB; copias de seguridad según retención.
Entrenamiento	4 trabajos de 2 h	32 vCPU-h y 128 GB-h al mes con 4 vCPU y 16 GB; sin GPU.
Servicio de consulta	Hasta 1.000 predicciones/día	Contenedor de 1 vCPU y 2 GB con escalado a cero o mínimo bajo.
MLflow	Metadatos continuos y artefactos de cada ejecución	Tracking Server pequeño; esquema SQL y almacenamiento de objetos compartido.
Monitorización	Aproximadamente 1 GB de logs al mes	Alertas de fallos, latencia, datos caducados y deriva.

Escenario	Estimación mensual	Interpretación
Desarrollo local	0 euros incrementales	Docker y MLflow local sobre los equipos del proyecto; no incluye electricidad ni hardware.
Piloto cloud	25 a 60 USD	Rango orientativo sin impuestos, soporte ni gran transferencia de salida.
Expansión inicial	80 a 180 USD	Más parcelas, mayor retención, servicio con disponibilidad continua y monitorización ampliada.

La página pública de Azure muestra, como referencia, 12,41 USD al mes para la computación B1ms de MySQL Flexible Server antes de almacenamiento y copias; el resto del rango depende principalmente del tiempo activo de los contenedores y de la retención (Microsoft, 2026c). La solución académica puede empezar en local y migrar solo cuando la colaboración o el piloto requieran un servicio compartido.

9. Gestión del ciclo de vida con MLflow

MLflow Tracking organiza las ejecuciones en experimentos y registra parámetros, métricas, versiones de código y artefactos. Un Tracking Server compartido separa los metadatos, almacenados en una base SQL, de los artefactos como modelos y gráficos, guardados en almacenamiento de objetos (MLflow, 2026a). Esta separación encaja con MySQL y la estructura de datos ya definida en el repositorio del TFM.

Ciclo de experimentación y gobierno con MLflow

El modelo solo se promociona si mejora la referencia agronómica y supera la revisión del equipo.




Figura 3. Ciclo propuesto de experimentación, validación, registro y monitorización.

Etapa	Información registrada	Control de aceptación
Preparación	Hash o versión del dataset, periodo, variables y commit de Git.	Partición temporal reproducible y ausencia de datos futuros.
Entrenamiento	Algoritmo, hiperparámetros, semilla y duración.	Ejecución repetible dentro del entorno declarado.
Evaluación	MAE, RMSE, R ² , gráficos de error y resultados por periodo.	Comparación con FAO-56 y revisión agronómica.
Registro	Modelo, firma, ejemplo de entrada, dependencias y artefactos.	Etiqueta validation_status=pending o passed.
Promoción	Versión aprobada y motivo de la decisión.	Alias candidate y champion; no usar las etapas antiguas, ya obsoletas.
Monitorización	Faltantes, latencia, deriva y error cuando exista valor observado.	Reentrenar o retirar el alias si se incumplen umbrales.

La documentación actual de MLflow recomienda alias y tags para organizar y desplegar versiones del modelo; los model stages tradicionales están obsoletos (MLflow, 2026b). Por ello, la práctica propone un alias candidate para la versión en revisión y champion para la versión aprobada. La reasignación del alias no elimina la versión anterior y mantiene la trazabilidad.

9.1 Encaje con el repositorio del Módulo 2

El repositorio público ya contiene src/models, models, results, config, tests, Docker y los ficheros de dependencias. MLflow todavía no aparece en requirements.txt. La implantación se plantea como un siguiente incremento y no se presenta como una funcionalidad existente.

Ubicación existente	Uso propuesto
src/models	Scripts de entrenamiento y evaluación con llamadas a MLflow Tracking.
config	Plantilla de MLFLOW_TRACKING_URI y nombres de experimento, sin credenciales reales.
models	Documentación de modelos aprobados; los binarios se guardan en el artifact store.
results/figures y reports	Gráficos e informes exportados para la memoria y comparación de experimentos.
tests	Pruebas de esquema, ausencia de fuga temporal y carga del modelo registrado.
requirements.txt y environment.yml	Añadir mlflow y el conector SQL cuando comience la implementación.
.gitignore	Excluir mlruns, bases locales, artefactos, .env y credenciales.

La práctica del Módulo 9 se entrega como documento independiente. Esta propuesta describe cómo se integraría MLflow con el proyecto del Módulo 2, pero no añade archivos ni modifica el repositorio.

10. Caso práctico aplicado

10.1 Enunciado

A las 07:00, el responsable de una parcela piloto de pimiento consulta el DSS. La temperatura, la radiación y la evapotranspiración de referencia están disponibles, pero la lectura de humedad del suelo tiene más antigüedad que el umbral permitido. El sistema detiene la recomendación y solicita una actualización. A las 08:00, un técnico incorpora una lectura válida; el modelo v0.3 propone 4,0 mm/día. El responsable ajusta la dosis a 3,5 mm/día porque observa humedad elevada y registra el motivo. Durante la carga nocturna, la API meteorológica había sufrido un timeout y terminó correctamente después de un reintento.

10.2 Solución

El caso de negocio incluye consultar parcela, detectar datos caducados, completar medición, validar, mostrar recomendación, ajustar y registrar dosis final. Deben conservarse la parcela pseudonimizada, el cultivo, el estado de las entradas, la dosis propuesta, la dosis aplicada y el motivo. El caso técnico registra el timeout, el reintento y el resto del pipeline, con la fuente, el número de filas, el estado, la duración y la versión de datos.

El análisis de descubrimiento medirá la frecuencia del bucle de actualización de humedad y su efecto sobre el tiempo de ciclo. Si se repite, la mejora puede consistir en alertar antes de la consulta o automatizar la lectura. La comprobación de conformidad buscará recomendaciones emitidas sin una validación vigente y reintentos que superen el umbral acordado. En MLflow quedarán registrados el dataset, el commit, las variables, el algoritmo, los parámetros, las métricas temporales, los artefactos y el estado de validación del modelo v0.3.

11. Riesgos, limitaciones y próximos pasos

La principal limitación es la ausencia inicial de logs reales de uso. Los ejemplos de este documento sirven para diseñar el esquema, pero no permiten afirmar qué variantes serán frecuentes. La disponibilidad de las APIs públicas tampoco está garantizada de forma continua, y algunas variables de parcela, como la humedad del suelo o la dosis realmente aplicada, pueden no existir sin sensores o colaboración del usuario.

El Process Mining puede inducir conclusiones erróneas si los identificadores de caso cambian, las marcas temporales no comparten zona horaria o una misma actividad se registra con nombres distintos. También existe riesgo de vigilar al usuario en lugar de mejorar el proceso. La recopilación debe limitarse a los eventos necesarios, pseudonimizar parcelas y explicar el uso de los datos. En el plano predictivo persisten la deriva climática, la fuga temporal y la generalización limitada del piloto de Almería.

- Definir el diccionario de eventos, responsables, zonas horarias y reglas de calidad.
- Instrumentar primero un log técnico real, porque puede validarse sin esperar usuarios finales.
- Crear un experimento local de MLflow y registrar la línea base FAO-56 y un modelo de regresión.
- Aplicar Inductive Miner y conformidad sobre los primeros casos, documentando cualquier dato sintético.
- Recalcular el presupuesto cloud con la calculadora cuando se conozcan región, retención y concurrencia reales.
- Realizar una validación agronómica antes de usar una recomendación en una explotación.

12. Enlace Github del Proyecto

Para finalizar, añadiremos el enlace al github del Proyecto <https://github.com/al1sr/tfm-regadio-dss>

Referencias bibliográficas

- Agencia Estatal de Meteorología. (s. f.). AEMET OpenData. Recuperado el 18 de septiembre de 2026, de <https://opendata.aemet.es/centrodedescargas/inicio>
- Allen, R. G., Pereira, L. S., Raes, D., y Smith, M. (1998). Crop evapotranspiration: Guidelines for computing crop water requirements (FAO Irrigation and Drainage Paper No. 56). Food and Agriculture Organization of the United Nations. <https://www.fao.org/4/x0490e/x0490e00.htm>
- Berti, A., van Zelst, S. J., y van der Aalst, W. M. P. (2019). Process mining for Python (PM4Py): Bridging the gap between process- and data science. Proceedings of the ICPM Demo Track 2019, 13-16. CEUR-WS. <https://ceur-ws.org/Vol-2374/paper4.pdf>
- IEEE. (2016). IEEE Standard for eXtensible Event Stream XES for achieving interoperability in event logs and event streams (IEEE Std 1849-2016). <https://doi.org/10.1109/IEEESTD.2016.7740858>
- MLflow. (2026a). MLflow Tracking. Recuperado el 18 de septiembre de 2026, de <https://mlflow.org/docs/latest/ml/tracking/>
- MLflow. (2026b). Model Registry workflows. Recuperado el 18 de septiembre de 2026, de <https://mlflow.org/docs/latest/ml/model-registry/workflow/>
- Mell, P., y Grance, T. (2011). The NIST definition of cloud computing (NIST Special Publication 800-145). National Institute of Standards and Technology. <https://doi.org/10.6028/NIST.SP.800-145>
- Microsoft. (2026a). Azure pricing calculator. Recuperado el 18 de septiembre de 2026, de <https://azure.microsoft.com/pricing/calculator/>
- Microsoft. (2026b). Azure Retail Prices REST API overview. Recuperado el 18 de septiembre de 2026, de <https://learn.microsoft.com/rest/api/cost-management/retail-prices/azure-retail-prices>
- Microsoft. (2026c). Azure Database for MySQL Flexible Server pricing. Recuperado el 18 de septiembre de 2026, de <https://azure.microsoft.com/pricing/details/mysql/>
- Ministerio de Agricultura, Pesca y Alimentación. (s. f.). Sistema de Información Agroclimática para el Regadío. Recuperado el 18 de septiembre de 2026, de <https://servicio.mapa.gob.es/siarweb/>
- Ministerio para la Transición Ecológica y el Reto Demográfico. (s. f.). Boletín Hidrológico semanal. Recuperado el 18 de septiembre de 2026, de <https://www.miteco.gob.es/es/agua/temas/evaluacion-de-los-recursos-hidricos/boletin-hidrologico.html>
- Navarro-Hellín, H., Martínez-del-Rincón, J., Domingo-Miguel, R., Soto-Valles, F., y Torres-Sánchez, R. (2016). A decision support system for managing irrigation in agriculture. Computers and Electronics in Agriculture, 124, 121-131. <https://doi.org/10.1016/j.compag.2016.04.003>
- Rose, D. C., Sutherland, W. J., Parker, C., Lobley, M., Winter, M., Morris, C., et al. (2016). Decision support tools for agriculture: Towards effective design and delivery. Agricultural Systems, 149, 165-174. <https://doi.org/10.1016/j.agsy.2016.09.009>
- van der Aalst, W. M. P. (2016). Process mining: Data science in action (2.^a ed.). Springer. <https://doi.org/10.1007/978-3-662-49851-4>
- Zaharia, M., Chen, A., Davidson, A., Ghodsi, A., Hong, S. A., Konwinski, A., et al. (2018). Accelerating the machine learning lifecycle with MLflow. IEEE Data Engineering Bulletin, 41(4), 39-45. <http://sites.computer.org/debull/A18dec/p39.pdf>

Anexo. Red de Petri conceptual

La figura representa el flujo esperado de una consulta de riego. El token inicial se encuentra en el primer estado; las transiciones avanzan por consulta, validación, recomendación y decisión. Cuando los datos están incompletos, el proceso pasa por la transición de completar datos y vuelve a validar. En la implementación, PM4Py descubrirá el modelo desde los registros reales y permitirá compararlo con esta referencia.

Red de Petri conceptual del proceso de consulta

Los círculos son estados; los rectángulos son transiciones. El modelo real se descubrirá desde los event logs.




Figura 4. Red de Petri conceptual del proceso de consulta y su bucle de revalidación.